


Analisi e previsione del consumo energetico di un edificio residenziale



Dataset *energydata_complete* — 19.735 misurazioni a intervalli di 10 minuti, 11 gennaio – 27 maggio 2016.

Due fasi di lavoro

01

Analisi del dataset e dei modelli

Analisi esplorativa del dataset e dei modelli di regressione per scegliere il più performante.
Modelli: Linear Regression, Random Forest, Lasso
XGBoost e riduzione con PCA.

02

Previsione temporale

Previsione temporale con catch24, XGBoost multiorizzonte e confronto con una baseline di persistenza.

— Fase 01

Studio dataset del consumo energetico e ricerca del modello

Quali variabili spiegano il consumo energetico? Analisi esplorativa e confronto sistematico dei modelli di regressione.

Fase 01 · Il dataset





Dataset e Pre-processing

Dati: ~19.700 record orari completi su 29 colonne.

Feature Engineering: Estrazione di variabili temporali (ora, giorno, giorno della settimana, weekend) e calcolo della temperatura media interna ($T_{\text{indoor_mean}}$).

Il consumo mostra forti variazioni cicliche legate all'ora del giorno e al giorno della settimana.

Correlazione significativa tra temperature interne, temperatura esterna e picchi di utilizzo energetico.



Confronto tra modelli


Stessa procedura per tutti: scaling con *StandardScaler*, split casuale 80/20, valutazione con MAE, RMSE e R^2 .

- **MAE** — errore medio assoluto, in Wh
- **RMSE** — penalizza gli errori grandi
- **R^2** — quota di variabilità spiegata

La regressione lineare spiega appena il 15% della variabilità: il legame fra le variabili e il consumo non è lineare.

Modello	MAE	RMSE	R^2
Regressione lineare	54,35	98,15	0,154
Gradient Boosting	47,31	89,94	0,290
Random Forest (100 alberi)	36,91	77,31	0,475

Il Random Forest triplica l' R^2 della regressione lineare. La direzione dello studio è decisa: modelli basati su alberi.



Selezione delle variabili: meno non è sempre meglio

Il risultato migliore si ottiene togliendo poche variabili scelte con criterio (rumore, pressione, visibilità, vento, punto di rugiada), ho ottenuto un R^2 di 0,56.

Ridurre tutto a poche variabili "essenziali" fa crollare l' R^2 : le variabili poco correlate singolarmente contribuiscono comunque in combinazione.

Valutazione del Modello di Regressione Lasso

L'obiettivo è valutare l'efficacia della regressione Lasso (e del parametro α) nella previsione dei consumi energetici, sfruttando la penalizzazione per ridurre l'overfitting e azzerare le variabili inutili.

Previsione con Lasso e Random Forest:

alpha	MAE	RMSE	R^2
0,1	52,51	91,17	0,169
0,5	52,45	91,21	0,169
1	52,45	91,30	0,167
10	54,23	94,00	0,117

Lasso resta però utile come strumento di selezione: con α 0,5 azzerava T7 e Tdewpoint; con α 1 anche pressione, rv1, rv2 e giorno.

Fase 01 · XGBoost

Utilizzo del modello XGBoost

XGBoost (*Extreme Gradient Boosting*)
costruisce molti alberi piccoli in sequenza:
ogni nuovo albero corregge l'errore residuo
dei precedenti e la previsione finale è la
loro somma.

È la scelta naturale per questo dataset che
contiene variabili correlate tra loro e relazioni
non lineari.

Con 2.000 alberi e learning rate 0,1: MAE 30,74
— RMSE 62,55 — **R² 0,609**. È il miglior
risultato di questa prima fase.

Numero di alberi	MAE	RMSE	R²
100	37,23	73,22	0,464
200	35,18	70,01	0,510
500	32,51	65,77	0,568
1000	31,29	63,50	0,597
2000	30,74	62,55	0,609

Il modello impara troppo bene il training

6,07

RMSE sul training

62,55

RMSE sul test

Il divario indica overfitting.


Configurazione	MAE	R²
lr 0,1 — 2.000 alberi	30,74	0,609
lr 0,05 — 4.000 alberi	30,51	0,609
lr 0,01 — 8.000 alberi	31,63	0,585

— Fase 01 · Importanza delle variabili

Importanza delle variabili

XGBoost attribuisce la quota maggiore di importanza alle variabili di calendario: Come mese, ora e giorno della settimana.

È una lettura coerente il problema: il consumo dipende dalle abitudini degli abitanti e dalla stagione.




Importanza calcolata sul modello a 2.000 alberi


PCA e perché non funziona

La PCA risolve la multicollinearità riducendo le colonne (es. da 29 a 12 componenti per il 93% di varianza), ma fa peggiorare XGBoost (R^2 da 0.61 a 0.43).

Questo accade perché "mescola" le variabili in valori astratti, impedendo agli alberi decisionali di isolare facilmente informazioni chiave come l'ora del giorno.



Confronto di tutti i modelli di regressione



Il modello migliore spiega il 61% della variabilità del consumo. Ma è una regressione su dati mescolati casualmente: non risponde ancora alla domanda "quanto si consumerà fra un'ora?".

 Fase 02

Previsione delle Serie Temporal di Consumo Energetico con XGBoost

Tre approcci messi a confronto: catch24, XGBoost
multi-orizzonte, modello di persistenza .

Cosa cambia rispetto alla fase precedente

Split: training, validation e test

70% training, 15% validation, 15% test, in ordine cronologico.

Solo informazione passata

Ogni statistica mobile è calcolata con *shift(1)* prima della finestra, così il valore da prevedere non entra mai nel calcolo delle proprie variabili predittive.

Nuove variabili costruite

Lag — i consumi a 10 minuti, 1, 2, 6, 12 e 24 ore e 7 giorni prima.

Statistiche mobili — media e deviazione standard delle ultime 1, 3, 6 e 24 ore: dicono al modello se la casa è stata attiva o ferma di recente.

Variabili cicliche — seno e coseno di ora e giorno della settimana, perché le 23 sono vicine alle 00 e il modello deve saperlo.

Catch 24

Catch24 è un insieme di 24 caratteristiche canoniche che riassumono una serie temporale.

Per adattare la serie storica a una tabella piatta compatibile con XGBoost, vengono combinate 172 feature (120 da catch24, dati originali, temporali, lag e statistiche). Infine, tramite SelectFromModel e soglia mediana, vengono selezionate e conservate solo le 86 migliori.

Perché fallisce:

catch22/24 è nato per sintetizzare serie storiche in pochi valori e confrontarle tra loro. Non è stato pensato per essere ricalcolato dinamicamente a ogni riga.

I lag e le medie mobili descrivono già la dinamica temporale senza la complessità di catch24.

Il modello tende a sovrastimare il consumo e fallisce perché aumentare la complessità e il numero di variabili non può compensare l'assenza di un vero segnale predittivo.

172
variabili totali

86
selezionate

XGBoost + catch24, orizzonte 24 ore (1500 alberi)

MAE	89,53
RMSE	113,95
R²	-0,539

R² negativo: il modello è peggiore della semplice media del test set.

XGBoost ‘multi-orizzonte’

Viene definita una funzione per spostare il target in avanti nel tempo (shift(-144) (24 ore) e simili) in base a diversi orizzonti temporali (da 1 ora fino a 1 settimana)

Viene eseguito un ciclo per addestrare un XGBRegressor su ciascuno dei diversi orizzonti temporali definiti, valutandone le prestazioni finali sul set di test.

Solo l'orizzonte a 1 ora resta appena sopra lo zero. Da 2 ore in poi l' R^2 è **negativo**.

L'andamento non è monotono: a una settimana R^2 torna positivo perché il modello ritrova la periodicità settimanale.


Orizzonte	MAE	RMSE	R^2
1 ora	52,05	88,65	0,060
2 ore	65,63	98,72	-0,165
6 ore	70,71	104,13	-0,295
12 ore	84,88	124,72	-0,855
24 ore	73,73	110,41	-0,464
1 settimana	52,45	92,28	0,011

800 alberi, learning rate 0,05, profondità 5 — dati a 10 minuti


Problemi:

- Un lag di 10 minuti è sensibile al ‘rumore casuale’, come all’accensione di un elettrodomestico, che è un evento casuale.
- Il modello insegue i picchi invece di capire l’andamento del consumo.


Reale vs Predetto — 6 ore




Reale vs Predetto — 12 ore



Reale vs Predetto — 24 ore



Reale vs Predetto — 1 settimana



Cambio di Task

Aggregazione oraria

Media su **un'ora** di tutte le variabili: elimina il rumore stocastico e lascia emergere i ritmi della routine quotidiana.

Trasformazione logaritmica

$\log(1 + x)$ sul target comprime i picchi senza alterare l'ordine dei valori, rendendo la distribuzione più simmetrica. La previsione viene poi riportata in Wh.

Baseline naïve di persistenza

La previsione più semplice possibile: fra un'ora si consumerà quanto si consuma adesso.

È il riferimento che mancava. Se un modello complesso non batte questa regola, non ha imparato nulla oltre a copiare l'ultimo valore disponibile.

Variabili: lag a 1, 2, 3, 6, 12, 24 e 168 ore, medie e deviazioni standard mobili a 3 e 24 ore, variabili cicliche.

Modello di Persistenza


Orizzonte 1 ora	Baseline naïve	XGBoost
MAE	31,71	40,59
RMSE	—	56,38
MedAE	—	29,54
R ²	0,312	0,405

XGBoost: 300 alberi, learning rate 0,03, profondità 5, target logaritmico.

In termini di errore medio, il risultato migliore dell'intero lavoro di previsione è quello della **baseline**: 31,71 Wh contro i 40,59 del modello.

Prima di addestrare modelli complessi, viene calcolata la performance di un modello di persistenza banale $y_{t+1} = y_t$, utilizzato come termine di paragone

Il modello addestrato ha un R^2 superiore — coglie meglio la forma generale della curva — ma **sbaglia in media 9 Wh in più** della regola banale di persistenza.




Fase 02

Dove sbaglia il modello

Il modello sovrastima leggermente il consumo di base e sottostima i picchi. È la firma tipica di un target asimmetrico con eventi rari non completamente spiegabili dalle variabili disponibili.

Confronto Consumo Reale vs Predetto a Diverse Scale Temporali



Conclusione

Scelta del modello

XGBoost usando tutte le variabili disponibili.
Le variabili di calendario — mese, ora, giorno della settimana — pesano più delle condizioni ambientali: il consumo è guidato dalla routine.

Sulla previsione

Nessun modello addestrato batte la **persistenza** in termini di errore medio. Su un orizzonte di un'ora, il consumo attuale è la migliore stima del consumo successivo.

Sul metodo

- Complessità maggiore non significa prestazioni migliori: catch24 e PCA hanno entrambe peggiorato i risultati.
- La scala temporale dei dati è una scelta di modellazione: aggregare a un'ora ha ridotto il rumore più di qualsiasi regolazione dei parametri.

— Fine della presentazione

Grazie per l'attenzione

- Sofia De Togni VR501921
